

合肥师范学院

本科生毕业设计（论文）

题目：基于卷积神经网络的数据驱动故障
预测

学 院	计算机与人工智能学院
学科门类	工 学
专 业	物联网工程
学 号	1907431008
姓 名	陈一鸣
指导教师	胡必玲、钱婧

2023 年 5 月 20 日

承诺书

本人向合肥师范学院提出学士学位申请，本人郑重声明：所提交的学位论文是本人在导师的指导下独立完成的。据我所知，除文中特别加以说明、标注和致谢的地方外，论文中不包括其他人已经发表或撰写过的研究成果，也不包括其他人为获得任何教育、科研机构的学位或证书而使用过的材料。

在此本人郑重承诺：所提交的学位论文不存在舞弊作伪行为，文责自负。

学位申请人（学位论文作者）签名： 陈一鸣

2023 年 5 月 20 日

为确保本科毕业论文（设计）质量，本人已对该生学位论文的学术性、规范性进行了全面审查，该生学位论文符合学校有关文件要求。

学位论文指导教师签名： 胡永平

2023 年 5 月 20 日

摘 要

随着中国制造 2025 的提出，工业智能制造是当前工业的热点。以往只要求将产品生产出来，而随着科技的进步，如今产品的运行维护与状态监测显得尤为重要。产品是否出现故障，寿命预测等问题受到了学术界的重点关注。故障诊断检测以前主要采用人工设计的特征，比如通过频率、均方根、峰度和波峰等。而近年来，人工智能技术的持续进步，它使得轴承故障诊断有了新的突破。

旋转机械故障特征人工提取需要大量的时间和精力，并且大多依靠专家经验。对于复杂故障识别显得尤为困难，诊断模型鲁棒性差。本文首先构建了一个一维卷积神经网络，拥有五个卷积池化对，一个全连接层，一个输出层。通过凯斯西储大学（CWRU）公共轴承数据集对模型进行测试，通过 t-SNE 方法对卷积神经网络中间层进行可视化分析，用混淆矩阵和准确率对模型进行评估。利用 Tensorflow 框架实现了将原始振动信号转换为振动灰度图。通过实验证明了一维卷积神经网络模型的有效性。

关键词：卷积神经网络；深度学习；故障诊断

Abstract

With the proposal of Made in China 2025, industrial intelligent manufacturing is a hot topic in current industry. In the past, products were only required to be produced, but with the progress of science and technology, the operation maintenance and condition monitoring of products are particularly important now. Product failure, life prediction and other issues have been the focus of academic circles. In the past, the fault diagnosis detection mainly adopted the artificially designed features, such as frequency, root mean square, kurtosis and wave crest. In recent years, the continuous progress of artificial intelligence technology has made new breakthroughs in bearing fault diagnosis.

It takes a lot of time and energy to extract the fault characteristics of rotating machinery manually, and most of them rely on expert experience. It is particularly difficult to identify complex faults and the robustness of the diagnostic model is poor. In this paper, we first construct a one-dimensional convolutional neural network with five pooling pairs, one fully connected layer and one output layer. The model was tested with the Case Western Reserve University (CWRU) public bearing data set. The t-SNE method was used to visualize the convolutional neural network intermediate layer, and the confusion matrix and accuracy were used to evaluate the model. Tensorflow framework is used to convert the original vibration signal into vibration gray level map. The effectiveness of one-dimensional convolutional neural network model is proved by experiments.

Key Words: Convolution neural network; Deep learning ;Fault diagnosis

目 录

摘 要	I
Abstract.....	II
1. 引言	1
1.1 研究背景及意义	1
1.2 基于深度学习的轴承故障诊断研究现状	1
1.3 研究内容及文章结构	3
1.3.1 主要研究内容	3
1.3.2 文章结构	3
2. 滚动轴承故障机理	4
2.1 滚动轴承的基本结构	4
2.2 滚动轴承故障原因及诊断方法	4
2.3 滚动轴承振动机理及故障特征频率	5
3. 卷积神经网络基本原理分析	7
3.1 卷积神经网络基本结构	7
3.1.1 输入层	7
3.1.2 卷积层	7
3.1.3 批标准化层	7
3.1.4 激活层	8
3.1.5 池化层	9
3.1.6 全连接层	10
3.1.7 输出层	10
3.2 卷积神经网络模型训练流程	10
3.3 卷积神经网络的优化策略	11
3.3.1 优化算法	11
3.3.2 学习率	11
3.3.3 损失函数	12
3.3.4 缓解过拟合	12
4. 实验过程与分析	14
4.1 网络模型结构	14
4.2 模型算法流程	15
4.3 实验数据简介	17
4.4 实验结果分析	17
4.4.1 振动信号灰度图	17
4.4.2 降维可视化	19
4.4.3 诊断结果与分析	20
5. 结语	22
5.1 全文总结	22

5.2 研究展望	22
参考文献	23
致 谢	24

1. 引言

1.1 研究背景及意义

设备的可靠性维护作为重点发展方向之一，受到国内外的持续关注。《“十四五”智能制造发展规划》将“装备故障诊断与预测性维护”列为到 2025 年需突破的关键技术之一，并支持面向产品全生命周期和制造全过程的 PHM 核心软件开发。美国国家科学技术委员会于 2018 年发布的《先进制造业美国领导力战略》报告指出要将先进的传感和控制技术和大数据分析应用于制造活动，以预测和改进产品的性能和可靠性。

轴承是工业界非常重要的零部件之一，飞机的升空，坦克的运转，各种机械设备中都需要轴承的支持，没有轴承国家的军事设备也无法运转。轴承故障十分常见并且极为重要，所以本文以轴承为研究对象详细探讨一下其中的原理以及用卷积神经网络进行轴承故障诊断的流程。

由于现代系统复杂性的增加，故障多样性的增加，依靠传统方法进行有效的故障诊断也变得越来越困难。故障诊断本质上是一个模式识别问题，传统的故障诊断方法，用传感器获取数据以后，进行谱分析、统计分析等方法得到一个状态的指标，根据阈值判断该设备是否有故障。传感器随着现代科技的发展，传感器本身也越来越智能，它不仅具有简单的数据采集功能，可能还会做数据预处理等。通过对安装在机器设备上的多源传感器信号分析，可以分析机器的运行状态、诊断故障和预测剩余寿命。安装在机器设备上的传感器越来越多，机器的运行速度越来越高，如何高效快速处理海量传感器数据、实现敏捷在线诊断是一个挑战。

1.2 基于深度学习的轴承故障诊断研究现状

深度学习（Deep Learning, DL）错误！未找到引用源。是机器学习领域中一个新的研究方向，成为人工智能领域研究的热点。如今随着 GPU 的普及，大数据时代的来临，数据量呈现不断增长的势态，而当数据量越来越大时，深度学习的优势非常明显，如图 1-1 所示。所以深度学习更应该用在拥有超大数据量的工业智能诊断中。

2018 年，同济大学周奇才^[2]等人基于经典卷积神经网络 AlexNet，提出了 1DCNN 的故障诊断模型，应用于轴承和齿轮箱健康状态监测。2017 年华中科技大学 Wen^[3]等人提出了基于 LeNet-5 的新型 CNN 用于故障诊断，将信号转换为二维图像，在电机轴承数据集、自吸离心泵数据集、轴向柱塞液压泵数据集上进行了测试，取得了较好的诊断效果。2020 年，浙江大学的徐健^[4]等人基于 CWRU 公共轴承数据集，将振动信号处理成振动灰度图，

并通过连续小波变换和短时傅里叶变换将一维时序信号转换为二维信号，然后对模型进行训练，对比它们的准确率，也比较了基于深度卷积神经网络方法与基于时域统计特征和浅层机器学习方法在故障诊断中的效果。2021 年，中北大学李红梅^[5]等人以滚动机械设备作为研究对象，主要针对一维卷积神经网络的参数设置、多传感器信息融合、变转速工况下的特征提取以及域适应性四个方面进行研究，提出三种智能故障诊断模型。2021 年，南京航空航天大学的余传粮^[6]等人将齿轮箱动力学模拟实验台采集的振动信号基于连续小波变换（CWT）和 2D-CNN 的处理，提出了 CWT-CNN 模型故障诊断方法，然后对该模型各网络层提取特征的能力进行可视化分析。2018 年，哈尔滨工业大学朱^[7]等人提出了一种新型胶囊网络，它在预处理阶段，将一维信号转换为时频图。其次将图数据输入网络，利用两个卷积层提取更高的信息，在此基础上，对输出特征映射应用初始块来改善胶囊的非线性。然后，在动态路由后，利用胶囊的长度对故障类别进行分类。2016 年，苏州大学 Guo^[8]等人提出一种分层学习率自适应深度 CNN 模型，以轴承为研究对象，在故障模式识别和故障规模评价方面取得了不错的效果。2017 年，厦门大学 Sun^[9]等人基于齿轮裂纹故障信号采用双树复小波变换（DTCWT）对多尺度信号进行特征提取，再结合卷积神经网络方法从中自动识别故障特征。




图 1-1 深度学习与机器学习比较

应用深度学习模型需大量标注数据训练，服从独立同分布。而工业场景运行工况多变，同时机械设备通常难以带故障直接运行，导致失效数据难以获取，数据呈现不完备性。为了使深度学习更好的应用于轴承故障诊断领域，能让不同来源的数据也能用在故障诊断中，许多学者开展了一系列的域适应性算法工作。

2017 年，清华大学 xie^[10]等人提出了一种基于经验模态分解（EMD）和 CNN 相结合的旋转机械故障特征提取方法，设计并训练了一个完整的滚动轴承故障诊断结构。2018 年，

清华大学 Han^[11]等人将对抗性学习作为正则化引入 CNN，并据此提出了一种新型的深度对抗性卷积神经网络（DACNN）。通过添加了一个额外的判别分类器，可以开发一个对抗学习框架，用分割的数据子集训练卷积块，从而得到一个极大极小的两方博弈。

1.3 研究内容及文章结构

1.3.1 主要研究内容

本文针对当前 CNN 模型故障诊断方法中存在的问题，用基于数据驱动的卷积神经网络模型技术对轴承常见故障进行了特征学习和分类，主要完成以下工作：

- （1）本文提出一种一维深度卷积神经网络，利用数据增强技术，通过数据预处理、卷积神经网络模型搭建、参数选取、模型训练、模型测试等步骤，对滚动轴承故障诊断给出了完整的流程，并利用 CWRU 数据集进行实验，给出训练结果和准确率，证明该模型的有效性和准确性。
- （2）本文用 Tensorflow 框架将原始振动信号转换为振动灰度图，从另一种角度区分了轴承故障的形式。
- （3）本文用 t-SNE 技术对卷积神经网络中间层可视化，证明了卷积神经网络技术对特征提取分类的可靠性。

1.3.2 文章结构

论文的章节内容安排如下：

第一章给出轴承故障诊断研究背景和常用方法，并介绍了目前研究的最新进展，总体上给出该课题的概览。

第二章介绍了滚动轴承的故障机理，包括滚动轴承的基本结构、轴承故障的常见原因，通过动力学建模，给出理想状态下，轴承中各部件的特征频率，为接下来的研究打下基础。

第三章主要介绍卷积神经网络的基本概念，基本构成，卷积神经网络训练流程和优化卷积神经网络模型训练的几种方法。

第四章首先提出基于卷积神经网络轴承故障诊断模型设计，给出卷积神经网络结构，模型算法训练流程，最后给出实验结果并进行分析。

第五章结语首先总结全文工作内容，然后给出本文对滚动轴承故障诊断领域方面未来展望。

2. 滚动轴承故障机理

本章将介绍滚动轴承的基本结构，故障原因以及常用的诊断方法，通过动力学建模给出滚动轴承的故障特征频率。

2.1 滚动轴承的基本结构

一个典型的滚动轴承可以分为以下部件：内圈、外圈、滚动体和保持架，如图 2-1 所示。




图 2-1 滚动轴承的基本结构

其中滚动轴承外圈一般固定在轴承座上^[12]，支撑滚动体，内圈通常与轴配合，并与轴一起旋转。滚动体位于外圈和内圈之间，滚动体分为锥柱体、圆柱体、球体等。有的轴承还有密封圈，其作用主要是延长轴承的使用寿命，保存润滑剂，防止异物侵入。

2.2 滚动轴承故障原因及诊断方法

常见的轴承故障原因要有以下几种：

（1）疲劳

疲劳往往是由润滑不足引起，当润滑不良时，金属与金属直接接触，随着轴承的持续运转，由于材料疲劳，会出现裂缝，然后就是剥落。

（2）磨损

磨损通常是由于密封性不好导致异物进入，引起损伤、擦伤，这种磨损会使使游隙增大，振动加剧，从而减少使用寿命。

（3）断裂

滚动轴承在工作时往往带有负载，如果局部负载过高超过了材料的强度极限，会出现轴承断裂。除此之外润滑不良、温度过高等也会导致轴承发生断裂。

（4）锈蚀

大多数轴承都是金属材料制造的，由于轴承密封性不好导致酸、碱性液体、水分、湿气

的侵入或者因为电流击穿和氧化等原因，会出现锈蚀现象。

（5）变形

当轴承在工作过程中遇到很大的静态负荷或冲击负荷时，会产生过载，导致塑性变形，在滚道上形成凹痕。

轴承可以分为向心和推力轴承。根据轴承的结构进行分类，即外圈故障、滚动体故障、保持架故障、内圈故障。它们都会在振动信号中产生特定的特征信号。

针对不同的故障情况和不同的运行工况，发展了很多不同的故障诊断方法：振动分析法、声发射分析法、温度监测法、油液分析法、电压电流检测法。

表 2-1 轴承常用故障诊断方法

方法	简介	优势	劣势
振动分析法	安装振动传感器采集振动信号	适合多类型、类工况的轴承	早期故障诊断略差
声发射分析法	安装声发射传感器分析声音信号	对早期故障敏感	测量设备昂贵/声音信号容易衰减
温度监测法	通过温度计或热成像仪等方法记录轴承运行温度	实施简单	不易捕捉微小的损伤，受环境影响
油液分析法	提取轴承润滑油进行光谱分析	直接简单	易受干扰/依赖经验
电压电流检测法	对电机的电压和电流变化检测分析	易测量	易受其它机械部件的影响

其中振动信号易测量、抗干扰能力强，所以用振动信号来进行轴承故障诊断是一种有效的方法。本文主要研究基于振动信号处理的旋转机械故障诊断方法。

2.3 滚动轴承振动机理及故障特征频率

很多旋转机械设备在实际运行过程中常常会遇到非简谐的周期激励力的作用。对于不健康有故障的轴承，比如滚道和滚动体之间的故障会使其相互作用产生时变和不均匀的不连续力，从而引发振动。

轴承的振动信号是用于故障诊断最原始的数据，由轴承工作时滚动体与内外圈滚道之间载荷激励产生。传统的诊断方法是看着振动或噪音谱线去找特征频率的，这是一件非常

有意义的事情。具体方法如下。

当轴承出现故障时，不同轴承部位对应的轴承理论故障振动频率：

内圈：BPFI（Ball Pass Frequency on Inner race）

$$f_i = \frac{Df_r}{2} \left(1 + \frac{d_b}{D} \cos \theta\right) \quad (1)$$

外圈：BPFO（Ball Pass Frequency on Outer race）

$$f_b = \frac{Df_r}{2} \left(1 - \frac{d_b}{D} \cos \theta\right) \quad (2)$$

滚动体：BSF（Ball Spin Frequency）

$$f_b = \frac{Df_r}{d_b} \left(1 - \left(\frac{d_b}{D} \cos \theta\right)^2\right) \quad (3)$$

保持架：FTF（Fundamental Train Frequency）

$$f_b = \frac{f_r}{2} \left(1 - \frac{d_b}{D} \cos \theta\right) \quad (4)$$

以上各式中， D 为轴承直径， d_b 为滚动体直径， θ 为接触角， f_r 为轴转速， N 为滚动体的个数。以上公式均假设理想状态下，实际情况中会有些许偏差，但是大多数情况下仍可作为我们判断故障位置的根据。

3. 卷积神经网络基本原理分析

卷积神经网络 (Convolutional Neural Networks, 简称 CNN) 概念最早由加拿大神经生理学家 David Hunter Hubel 和瑞典神经科学家 Torsten Wiesel 在 20 世纪 50 年代和 60 年代提出, 近年来, CNN 已经成功地应用于图像识别等领域, 先后出现了 LeNet、AlexNet、VGGNet、ResNet 和 inceptionNet 等多种 CNN 架构^[13]。

3.1 卷积神经网络基本结构

3.1.1 输入层

输入层 (Input Layer) 是指将原始数据或者其他算法预处理后的数据输入到卷积神经网络中, 本文将原始振动信号预处理后输入到卷积神经网络的输入层。

3.1.2 卷积层

CNN 利用卷积运算代替神经网络中一般乘法运算, 卷积层的目的是为了提取输入中的特征, 如果不想输入中的边缘特征丢失, 可以使用全零填充, 即 padding。在 Tensorflow 中可以设定 padding 的取值是 same 来使用全零填充, 用 valid 不使用全零填充。卷积过程实际上是利用卷积核, 将两个矩阵做乘法。

用 Tensorflow 框架描述卷积层可用以下语句:

```
tf.keras.layers.Conv2D(
    filters=卷积核个数,
    kernel_size=卷积核尺寸,#正方形写核长整数, 或 (核高 h, 核宽 w)
    strides=滑动步长,#横纵向相同写步长整数, 或 (纵向步长 h, 横向步长 w)
    padding="same"or"valid",
    activation="relu"or"sigmoid"or"tanh"or"softmax"#如有 BN 此处不写
    input_shape=(高,宽,通道数)#输入特征图维度, 可省略
)
```

3.1.3 批标准化层

批标准化 (Batch Normalization) 简单的来说, 就是统一数据的标准规范, 让卷积神经网络更容易学习到数据中的规律。当神经网络中的层数越来越多时, 模型训练也会更加麻烦, 在每层后都加上批标准化层, 可以加速模型训练。批标准化操作通常位于卷积层和池化层之间, 如果只是简单的进行数据标准化, 会使模型丧失线性表达的能力, 因此加入两个参数, 一个是 γ 一个是 β , 在模型训练时, 他们也会参与前向传播和反向传播, 并与其他参数一样进行参数更新。

3.1.4 激活层

激活函数有许多，下面介绍几个典型的激活函数：

（1） Sigmoid

Sigmoid 函数定义如下：

$$f(x) = \frac{1}{1 + e^{-x}} \quad (5)$$

导数如下：

$$f(x)' = \frac{1}{1 + e^{-x}} \frac{e^{-x}}{1 + e^{-x}} \quad (6)$$




图 3-1 Sigmoid 函数和导数图像

图中红色曲线为 Sigmoid 图像，蓝色曲线是导数图像。以下部分均用红色曲线表示激活函数，用蓝色曲线绘出其导数图像。

Sigmoid 函数的值域是 $[0,1]$ ，这个激活函数会出现梯度消失的现象，当数据是很大的正数时，激活函数的值变化会很小，导致参数更新会很慢。

（2） tanh

tanh 函数定义如下：

$$f(x) = \frac{1 - e^{-2x}}{1 + e^{-2x}} \quad (7)$$




图 3-2 tanh 函数和导数图像

(3) ReLU (Rectified Linear Unit)

ReLU 函数定义如下：

$$f(x) = \max(x, 0) = \begin{cases} 0 & x < 0 \\ x & x \geq 0 \end{cases} \quad (8)$$




图 3-3 ReLU 函数和导数图像

目前用的最为广泛的就是 ReLU 函数，当输入是正数时，它的导数恒为 1，缺点就是当输入是负数时，他输出的函数值全为 0，这对模型训练非常不利，后来提出的 Leaky ReLU 在一定程度上解决了该问题。

3.1.5 池化层

池化层的主要作用是特征降维，将卷积层的输出特征图一些冗余的部分剔除，抽取更加重要的特征。

池化包含最大池化（max-pooling）和平均池化（mean-pooling），其中最大池化效果最佳。

用 Tensorflow 框架描述池化层可用以下语句：

```
tf.keras.layers.MaxPool2D(  
    pool_size  
    strides  
    padding  
)  
tf.keras.layers.AveragePooling2D(  
    pool_size  
    strides  
    padding  
)
```

3.1.6 全连接层

全连接层（Full Connected Layer）用来整合前面多个卷积层和池化层所提取的局部特征。全连接层是一个线性特征映射的过程，其神经元激活函数通常采用 ReLU 函数。

3.1.7 输出层

如果是分类问题，输出层的神经元个数与分类个数相同，以概率形式输出模型的识别结果。一般采用 Softmax 函数，将提取的特征转换为概率分布。

3.2 卷积神经网络模型训练流程

CNN 的样本集由一个形状为 (X, Y_p) 的样本对组成，其中 X 为输入向量， Y_p 为理想输出向量，学习过程如下：

- （1）初始化 CNN。为了避免过拟合，用不同的小随机数设置单层感知器的内核权值、偏置和参数。
- （2）训练 CNN 模型。从训练集中选取一个样本 (X, Y_p) ，将 X 输入到网络中，得到实际的输出向量 O_p 。
- （3）计算实际的输出向量 O_p 与理想输出向量 Y_p 之间的误差，得到各层参数的损失函数和误差。

- (4) 利用误差反向传播，通过梯度下降法计算损失函数的梯度，然后更新相应层的权值。公式如下：

$$w_{t+1} = w_t - l_r \times \frac{\partial loss}{\partial w_t} \quad (9)$$

其中 l_r 为学习率, w_t 为当前参数, w_{t+1} 为更新后的参数, $\frac{\partial loss}{\partial w_t}$ 为损失函数的梯度(偏导数)。

- (5) 重复训练过程，直到所有的训练样本都完成，这被称为学习过程。
- (6) 迭代。为了提高网络的准确性，重复学习过程，直到获得满意的分类率或达到迭代次数。
- (7) 将测试集输入训练好的 CNN，验证学习到的模型。

3.3 卷积神经网络的优化策略

3.3.1 优化算法

优化算法其实就是改善模型的训练方式，使其最终可以最大化或最小化损失函数，找到我们想要的各个参数值。最常用的梯度下降方法，它是一阶优化算法，用梯度下降逐渐逼近损失函数的最低点。二阶优化算法使用了二阶导数来最大化或最小化损失函数，这种方法没有被广泛使用。

目前的优化算法有随机梯度下降(SDG)、小批量梯度下降、Adagrad 等。本文使用 Adam 优化算法。Adam 是在 2014 年由 OpenAI 的 Kingma D 和多伦多大学的 Ba J 提出的一种能够在更新权重时自适应调节学习率的一中算法，Adam 名字来源是 adaptive moment estimation。Adam 实际上是把一阶动量和二阶动量结合，再修正偏差。Adam 的收敛速度很快，并且可以自适应的调节学习率，因此 Adam 算法也得到了广泛使用。

3.3.2 学习率

学习率策略主要有以下两种：

- (1) 指数衰减

指数衰减学习率指先用较大的学习率得到一个比较不错的解，然后不断迭代，一步一步逐渐减小学习率。

学习率通过指数衰减法设置：

$$decayed_rate = learning_rate \times decay_rate^{(global_step/decay_steps)} \quad (10)$$

其中 $learning_rate$ 是初始学习率, $decay_rate$ 是衰减率, $global_step$ 表示从 0 到当前的训练次数, $decay_steps$ 是用来控制衰减速度。

- (2) 分段常数衰减

分段常数衰减学习率基本思想是预先定义区间范围，在不同的区间范围上设置不同的

学习率。在设定一个步长，每隔固定步长衰减一次，逐渐使模型训练趋于稳定。

3.3.3 损失函数

神经网络模型的效果及优化的目标是通过损失函数来定义的。回归和分类是监督学习中的两个大类。

损失函数（loss）即预测值（ y ）与已知答案（ y_{-} ）的差距，损失函数可以自定义，也可以是均方误差（Mean Squared Error, MSE）或交叉熵（Cross Entropy, CE）。

（1）均方误差损失函数

均方误差损失函数是预测值和目标值的差值平方和再求平均，均方误差损失函数连续，处处可导，可以使用梯度下降法进行收敛。

MSE 定义如下：

$$MSE(y, y_{-}) = \frac{\sum_{i=1}^n (y_i - y_{i-})^2}{n} \quad (11)$$

其中 y_i 为一个 batch 中第 i 个数据的真实值，而 y_{i-} 为神经网络的预测值。

Tensorflow 中如下进行设置：

`Loss_mse = tf.reduce_mean(tf.square(y_-y))`

（2）交叉熵损失函数

交叉熵损失函数可以表征两个概率分布之间的距离，交叉熵的计算公式如下

$$H(y, y_{-}) = -\sum y \ln y \quad (12)$$

其中 y_{-} 是数据的真实值， y 是神经网络的预测值。交叉熵越大，两个概率分布越远，交叉熵越小，两个概率分布越近。Tensorflow 中可计算交叉熵损失函数的 API 是 `tf.keras.losses.categorical_crossentropy`。

3.3.4 缓解过拟合

过拟合是指在训练训练过程中，对于训练集的学习过于充分，使得它在训练集上表现得非常好，而在测试集上表现却很糟糕，这是因为模型学到了大量不必要的特征，因此在模型训练过程中如何缓解过拟合显得尤为重要。

缓解过拟合有很多办法，比如扩充数据集、改进模型、过早停止、正则化、Drouout 等，其中正则化是缓解过拟合的常用方法。

正则化有两种方式，分别为 L1 正则化和 L2 正则化，如下式所示：

$$loss_{L1}(w) = \sum_i |w_i| \quad (13)$$

$$Loss_{L2}(w) = \sum_i |w_i^2| \quad (14)$$

简单来说，L1 正则化是通过稀疏参数实现的，剔除一些没有用的特征。L2 正则化通过让参数很接近 0 但不为 0，使逻辑回归得出的结果更加平滑。

4. 实验过程与分析

4.1 网络模型结构




图 4-1 卷积神经网络模型结构

本文建立了一个有 5 个卷积池化对和 1 个全连接层, 1 个输出层的卷积神经网络结构, 将故障诊断问题转换为类似图像识别分类任务进行处理。由于 CWRU 数据集有 10 种故障情况, 最后 Softmax 层神经元个数设置为 10, 即 10 分类^[14]。

其中第一对卷积池化层, 卷积核大小为 64×1 , 步长 16×1 , 卷积核数目是 16, 输出大小是 128×16 的特征图, 使用全零填充。池化采用最大池化, 池化核大小为 2×1 , 输出大小为 64×16 的特征图, 不使用全零填充。

第二对卷积池化层, 卷积核大小为 3×1 , 步长是 1×1 , 卷积核数目是 32, 输出大小为 64×32 的特征图, 使用全零填充, 池化核大小为 2×1 , 输出大小为 32×32 的特征图, 不使用全零填充。

第三对卷积池化层, 卷积核大小为 3×1 , 步长是 1×1 , 卷积核数目是 64, 输出大小为 32×64 的特征图, 使用全零填充, 池化核大小为 2×1 , 输出大小为 16×64 的特征图, 不使用全零填充。

第四对卷积池化层, 卷积核大小为 3×1 , 步长是 1×1 , 卷积核数目是 64, 输出大小为 16×64 的特征图, 使用全零填充, 池化核大小为 2×1 , 输出大小为 8×64 的特征图, 不使

用全零填充。

第五对卷积池化层，卷积核大小为 3×1 ，步长是 1×1 ，卷积核数目是 64，输出大小为 6×64 的特征图，使用全零填充，池化核大小为 2×1 ，输出大小为 3×64 的特征图，不使用全零填充。

紧接着是全连接层和 Softmax 层，神经元个数分别设置 100 和 10。

4.2 模型算法流程

本节将介绍模型算法流程即基于卷积神经网络数据驱动故障诊断方案。具体流程如下图所示。

首先对 CWRU 数据集中的.mat 文件进行数据预处理，因为西储大学每一类的轴承故障数据都是振动数据，所以本实验利用重叠采样方法对数据进行处理，从而得到足够多的数据样本，然后将采样数据按一定比例划分为训练集、验证集和测试集。训练集进行模型的训练，测试集来评估模型的性能。验证集用来调整超参数。

接着将训练集、验证集和测试集喂入已经搭建好的卷积神经网络中进行模型训练，模型训练过程包括前向传播和反向传播两个部分，然后用 Adam 优化算法更新其中的参数，并自适应调整学习率。实验中将 Adam 优化算法中学习率初始化为 0.001。

Tensorflow 中进行如下设置：

```
optimizer = tf.keras.optimizers.Adam(learning_rate=0.001)
model.compile(optimizer=optimizer, loss='categorical_crossentropy',
              metrics=['accuracy'])
```

其中损失函数选用交叉熵损失函数，在全连接层和输出层之前设置 Dropout 为 0.5，在全连接层和输出层引入 L2 正则化，从而避免模型过拟合现象。全连接层的激活函数选用 ReLU，输出层的激活函数选用 Softmax。训练完成后保存模型参数，再通过测试集进行模型的评估。本文通过准确率对模型进行评估，用 t-SNE（t-distributed Stochastic Neighbor Embedding）降维可视化来评估模型的特征学习能力，用混淆矩阵直观的观察模型分类的准确率。

模型运行的软件环境为：Python 3.7.16 + Tensorflow 2.1；硬件环境为：Intel(R) Core(TM) i5-9300H + NVIDIA GeForce GTX 1650。

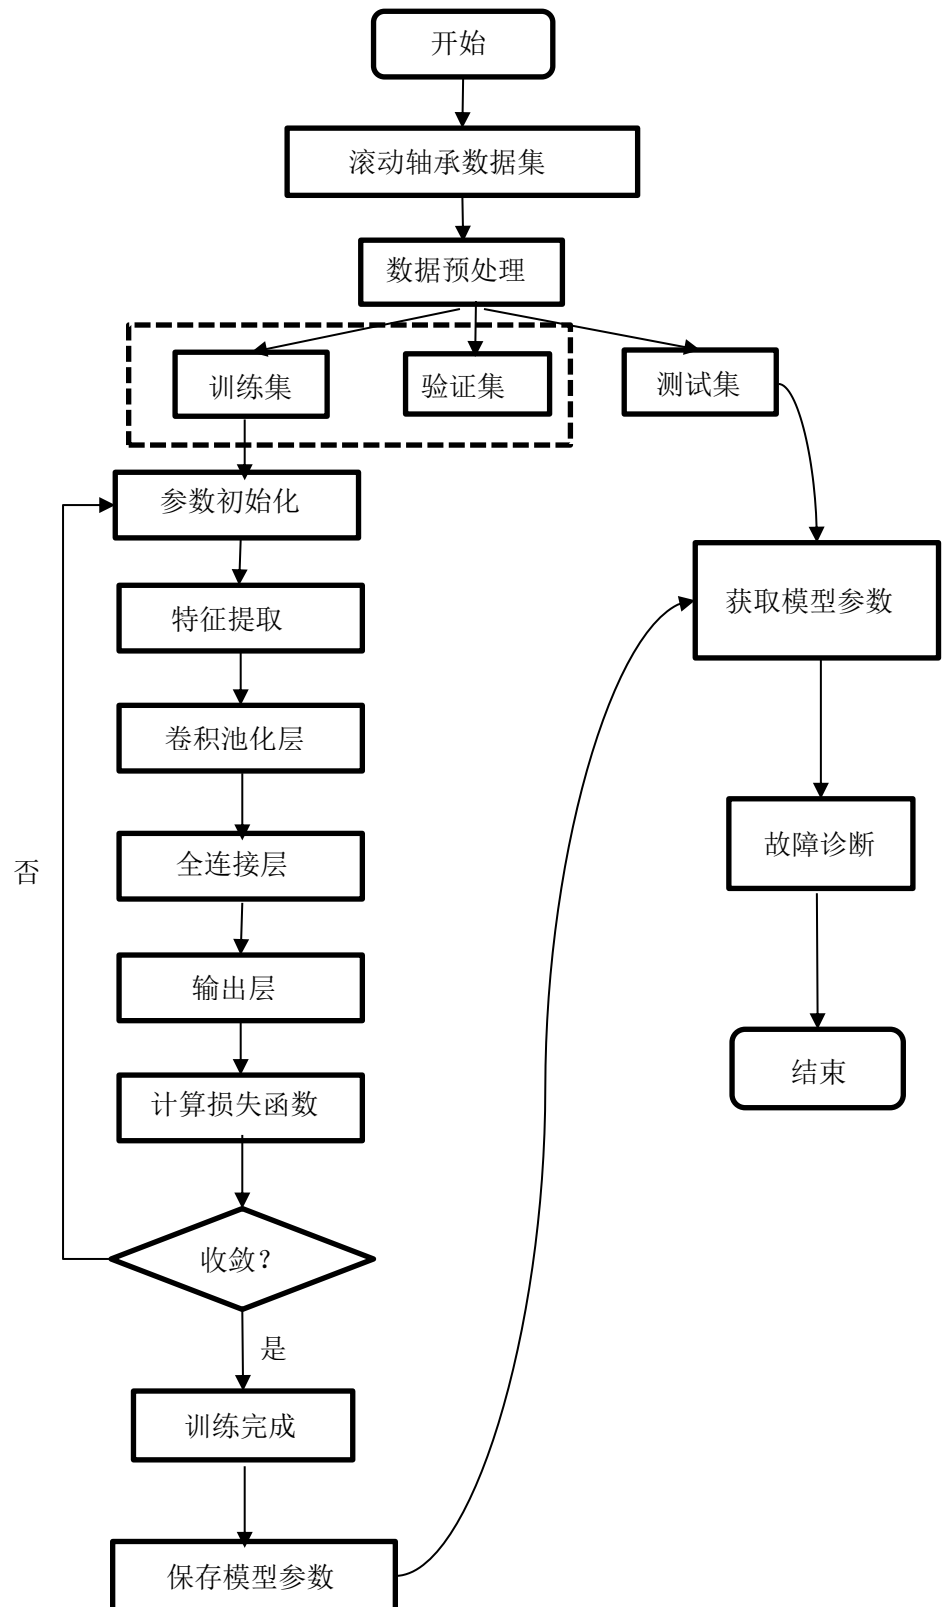


图 4-2 故障诊断流程图

4.3 实验数据简介

为进一步验证所提方法的有效性，选取凯斯西储大学滚动轴承试验台的真实数据进行验证分析。每秒采样频率为 12kHz 或 48kHz，其中加速度传感器用于测量轴承的振动信号。




图 4-3 凯斯西储大学滚动轴承测试台

在该实验中，故障轴承分别被安装在驱动端（6205-2RS JEM SKF）和风扇端（6203-2RS JEM SKF），有故障的轴承通过电火花加工法制造，在 4 种不同的电机负载下（0，1，2，3hp）。每种故障尺寸直径有 0.007 英寸、0.014 英寸、0.021 英寸，所以我们总共有 10 个故障情况。

4.4 实验结果分析

4.4.1 振动信号灰度图

为了从不同角度对故障轴承进行分类，本文基于 Tensorflow 框架将一维原始振动信号转换为二维的振动信号灰度图。




图 4-4 正常轴承的一维振动信号图




图 4-5 内圈故障的一维振动信号图




图 4-6 外圈故障轴承的一维振动信号图




图 4-7 滚动体故障轴承的一维振动信号图

卷积神经网络通常用于处理具有已知网格状形状的数据，例如二维图像数据或者一维时间序列数据。图 4-4 显示了 CWRU 数据集中四种状态的一维振动信号图。原始振动信号是一维的，所以振动灰度图方法就是将段一维时序信号中的 4096 个数据点转化为若干个 64×64 的图像。如下图所示：




图 4-8 滚动体故障的灰度图




图 4-9 外圈故障的灰度图




图 4-10 内圈故障轴承的灰度图




图 4-11 正常轴承的灰度图

4.4.2 降维可视化

由于神经网络模型是黑盒模型（Black box），可解释性差，t-SNE 方法得到的各样本所提取出的高维特征在降维后的特征空间中的可视化分布图如图 4-12 所示。

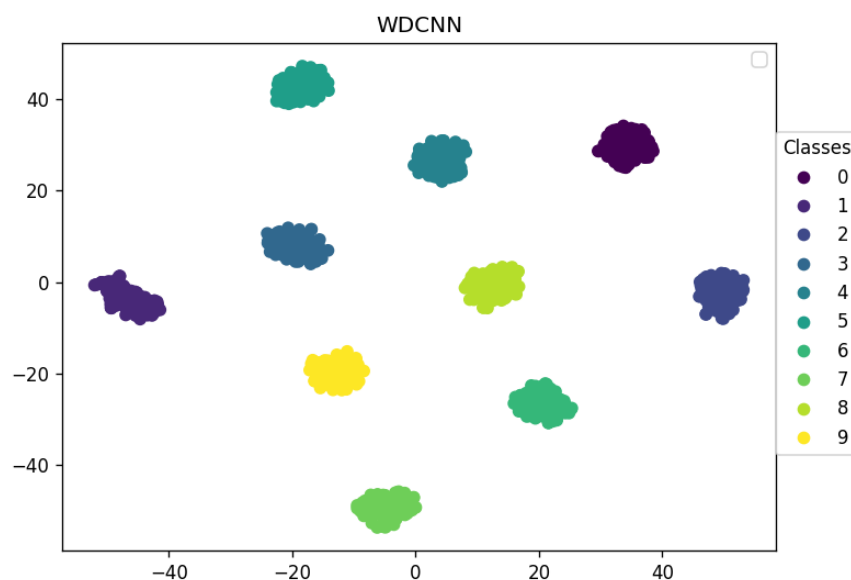


图 4-12 降维可视化

由图可见，经过卷积神经网络后，各类别数据特征成簇状形式，说明卷积神经网络已

经将特征提取并分类，故障诊断是一个模式识别问题，卷积神经网络可以很好的进行自动特征提取，也证明了该模型的可靠性。

4.4.3 诊断结果与分析

对用于图像分类任务的卷积神经网络，评价模型性能的指标主要有准确率(Accuracy)、查准率(Precision)、查全率(Recall)、ROC 曲线等。

如表所示为二分类结果的混淆矩阵，从中可以判断分类预测结果的好坏。

表 4-1 二分类结果混淆矩阵

真实情况	预测结果	
	正例	反例
正例	TP (真正例)	FN (假反例)
反例	FP (假正例)	TN (真反例)

查准率是正确预测的正反例数与总数的比值，查全率是正确预测到的正例数与实际正例总数的比值。

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (15)$$

$$Precision = \frac{TP}{TP + FP} \quad (16)$$

$$Recall = \frac{TP}{TP + FN} \quad (17)$$

为了可以清晰直观的观察模型的训练过程，图 4-13 是训练集和测试集的准确率和损失率与运行轮数的关系曲线图，说明了该模型的可靠性^[15]。由图中可以看出验证集准确率略低于训练集准确率，说明该模型并没有出现过拟合现象，可以加大训练轮数，进一步提高模型的准确率。

混淆矩阵是衡量模型准确率最直观的一种方式，本实验最终实现了 10 分类的轴承故障诊断，如图 4-14 是 10 分类结果的混淆矩阵。

x 轴为轴承故障检测的预测类型，y 轴表示为轴承故障检测的真实类型。在图中，模型中和判断准确率为 100%。所以该模型具有优秀的诊断性能，在工程轴承故障诊断中有不错效果。




图 4-13 训练集和测试集的准确率和损失率

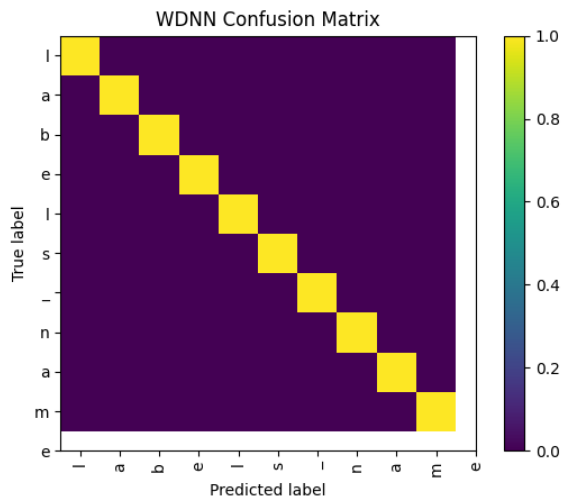


图 4-14 轴承故障诊断多分类混淆矩阵

5. 结语

5.1 全文总结

本文以滚动轴承为研究对象，基于振动信号处理设计出基于卷积神经网络的数据驱动故障诊断方法。主要成果和结论如下：

- （1）本文提出的一维卷积神经网络模型用于轴承故障诊断中效果优良，鲁棒性好。
- （2）本文基于 Tensorflow 框架将一维振动信号转换为二维振动灰度图，可以将故障形式直观的表达出来。
- （3）通过 t-SNE 技术表明本文所构建的卷积神经网络模型用在故障诊断中可以很好的对特征分类提取。

5.2 研究展望

实际工程装备中系统结构复杂，运行条件多变，许多轴承可能来自不同工况下，这时通常会用到域适应性方法，其分为目标域和源域。目标域数据少量甚至无标签，源域一般有标签，有大量数据，通过迁移学习可以解决数据的不完备性。

本文中所提出的基于卷积神经网络的数据驱动故障诊断是在 CWRU 数据集下实验的，没有考虑实际工业过程中的噪声影响。所以接下来的研究应加入一些噪声，提出一些处理噪声的方法，使得该模型具有更好的泛化能力。

如今，边缘计算是一种新兴的计算范式，边缘计算在网络边缘实现信号实时采集与处理。与“云计算”相比，具备低时延、高带宽、海量连接等特点，在多个领域上具有广泛应用前景。边缘计算的独特特点使其在机器设备实时异常检测、动态故障诊断上具有重要应用场景。所以边缘计算用在轴承故障诊断中是种不错的方法。

参考文献

- [1] 黄扣,袁伟,陈红卫.基于深度学习的轴承故障智能诊断方法研究[J].计算机与数字工程, 2022(008):050.
- [2] 周奇才,刘星辰,赵炯,等.旋转机械一维深度卷积神经网络故障诊断研究[J].振动与冲击, 2018, 37(23):7.DOI:10.13465/j.cnki.jvs.2018.23.005.
- [3] Wen L , Li X , Gao L , et al. A New Convolutional Neural Network-Based Data-Driven Fault Diagnosis Method[J]. IEEE Transactions on Industrial Electronics, 2017.
- [4] 徐健.基于卷积神经网络的风电机轴承故障诊断方法研究[D].浙江大学,2020.
- [5] 李红梅.基于卷积神经网络的智能故障诊断方法研究[D].中北大学,2021.
- [6] 余传粮.基于卷积神经网络的齿轮箱故障诊断[D].南京航空航天大学,2021.
- [7] 朱智宇.基于卷积神经网络的机械故障诊断域自适应算法研究[D].哈尔滨工业大学,2020.
- [8] Guo X , Chen L , Shen C . Hierarchical adaptive deep convolution neural network and its application to bearing fault diagnosis[J]. Measurement, 2016, 93:490-502.
- [9] Weifang S , Bin Y , Nianyin Z , et al. An Intelligent Gear Fault Diagnosis Methodology Using a Complex Wavelet Enhanced Convolutional Neural Network[J]. Materials, 2017, 10(7):790.
- [10]Xie Y,Zhang T.Fault Diagnosis for Rotating Machinery Based on Convolutional Neural Network and Empirical Mode Decomposition[J].Shock and Vibration,2017,(2017-8-20),2017(PT.5):1-12.
- [11]Han T , Liu C , Yang W , et al. A novel adversarial learning framework in deep convolutional neural network for intelligent diagnosis of mechanical faults[J]. Knowledge-Based Systems, 2018.
- [12]金国强.基于深度学习的复杂工况下端到端的滚动轴承故障诊断算法研究[D].中国科学技术大学,2020.
- [13]丁磊.基于卷积神经网络的滚动轴承故障诊断方法研究[D].华东交通大学,2022.
- [14]张伟.基于卷积神经网络的轴承故障诊断算法研究[D].哈尔滨工业大学,2017.
- [15]郭盛.基于卷积神经网络的旋转机械变工况故障诊断方法研究[D].华中科技大学,2019.

致 谢

永远回不去的叫曾经，感谢我的父母陈永柏先生和周先芳女士，是他们抚养我长大，教会我一样又一样东西，同时感谢胡必玲老师对我不厌其烦地培养，感谢钱婧老师的支持与帮助，感谢求学路上每个带给我知识，让我成长的人。

非常感谢胡必玲老师开设这个课题，为本人日后从事计算机方面的工作提供了经验，奠定了基础。本次毕业设计大概持续了半年，现在终于到结尾了。本次毕业设计是对我大学四年学习下来最好的检验。经过这次毕业设计，我的能力有了很大的提高，比如操作能力、分析问题的能力、合作精神、严谨的工作作风等方方面面都有很大的进步。这期间凝聚了很多人的心血，在此我表示由衷的感谢。

大学四年，时间过得很快，如果让我非常难忘的，那一定是每天去图书馆的充实日子，对我的人生有着重大影响。大学四年养成的学习习惯将成为我一辈子的榜样，我永远需要突破自己，永远积极向上。